

МОСКОВСКИЙ ГОРОДСКОЙ ПЕДАГОГИЧЕСКИЙ УНИВЕРСИТЕТ

Институт цифрового образования

Лабораторная работа 2.1

**«Создание полного dbt-проекта для преобразования сырых данных в
аналитические витрины»**

Выполнил студент 1 курса, БД-251м группы

Трусов А.И.

Москва – 2025

Архитектура DWH




Рисунок 1 - Архитектура DWH

Архитектура проекта

В моем dbt-проекте используется многоуровневая архитектура, которая хорошо видна на графе зависимостей:

Слой Intermediate (промежуточный)

- **Назначение:** Подготовка данных для витрин
- **Основные модели:**
 - int_sales_orders - соединяет факты продаж со всеми измерениями (customer_dim, product_dim, geo_dim, shipping_dim, calendar_dim)
 - int_orders_pivoted - сводная таблица с агрегированными метриками по клиентам
- **Зачем нужен:** Устраняет дублирование кода - сложные JOIN'ы выполняются один раз

Слой Marts (аналитические витрины)

- **Назначение:** Готовые данные для конкретных бизнес-задач
- **Основные витрины:**
 - mart_monthly_sales - для анализа продаж по месяцам
 - mart_customer_ltv - для расчета пожизненной ценности клиентов
 - mart_time_to_first_profit - мой индивидуальный проект (время до первой прибыли)
 - mart_valuable_dormant_customers - анализ ценных неактивных клиентов

Дополнительные компоненты

- **Snapshots:** snapshot_product_dim - отслеживает историю изменений в продуктах

- **Exposures:**
 - executive_dashboard - дашборд для руководства
 - marketing_analytics - аналитика для маркетинга
 - sales_performance_dashboard - дашборд продаж

Поток данных

Источники (dim таблицы + sales_fact) → **Intermediate** (подготовка) → **Marts** (финальные витрины) → **Exposures** (BI-дашборды)

Ключевые фрагменты кода

Код модели int_sales_orders.sql

```
-- models/intermediate/int_sales_orders.sql
-- Эта модель объединяет факты со всеми измерениями, создавая
-- широкую, денормализованную таблицу для легкого использования в витринах.

SELECT
  -- Ключи
  f.order_id,

  -- Измерения из customer_dim
  c.customer_id,
  c.customer_name,

  -- Измерения из product_dim
  p.product_id,
  p.product_name,
  p.category,
  p.sub_category,
  p.segment,

  -- Измерения из geo_dim
  g.city,
  g.state,

  -- Измерения из shipping_dim
  s.ship_mode,

  -- Даты из calendar_dim (с правильными псевдонимами)
  cal_order.date as order_date,
  cal_ship.date as ship_date,

  -- Метрики из sales_fact
  f.sales,
  f.profit,
  f.quantity,
  f.discount

FROM {{ source('dw_test', 'sales_fact') }} AS f
LEFT JOIN {{ source('dw_test', 'customer_dim') }} AS c ON f.cust_id = c.cust_id
LEFT JOIN {{ source('dw_test', 'product_dim') }} AS p ON f.prod_id = p.prod_id
LEFT JOIN {{ source('dw_test', 'shipping_dim') }} AS s ON f.ship_id = s.ship_id
LEFT JOIN {{ source('dw_test', 'geo_dim') }} AS g ON f.geo_id = g.geo_id
-- ИСПРАВЛЕНО: Добавляем псевдонимы, так как календарь используется дважды
LEFT JOIN {{ source('dw_test', 'calendar_dim') }} AS cal_order ON f.order_date_id =
cal_order.dateid
LEFT JOIN {{ source('dw_test', 'calendar_dim') }} AS cal_ship ON f.ship_date_id = cal_ship.dateid
```

Код индивидуальной mart-модели mart_time_to_first_profit.sql (вариант 29)

```
-- models/marts/mart_time_to_first_profit.sql
WITH customer_orders AS (
  SELECT
    customer_id,
    customer_name,
    first_order_date,
    last_order_date,
    total_profit,
    total_orders,
    -- Проверяем, была ли прибыль при первой покупке
    CASE
      WHEN total_profit > 0 THEN first_order_date
      ELSE NULL
    END AS first_profitable_order_date
  FROM {{ ref('int_orders_pivoted') }}
),

customer_profit_timeline AS (
  SELECT
    customer_id,
    customer_name,
    first_order_date,
    total_profit,
    total_orders,
    -- Если общая прибыль положительная, считаем что первая прибыльная покупка была при
    -- первой покупке
    CASE
      WHEN total_profit > 0 THEN first_order_date
      ELSE NULL
    END AS first_profitable_order_date,
    -- Количество дней до первой прибыли
    CASE
      WHEN total_profit > 0 THEN 0 -- Если прибыль с первой покупки
      ELSE NULL
    END AS days_to_first_profit,
    -- Флаг наличия прибыльных заказов
    total_profit > 0 AS has_profitable_order
  FROM {{ ref('int_orders_pivoted') }}
)

SELECT
  customer_id,
  customer_name,
  first_order_date,
  first_profitable_order_date,
  days_to_first_profit,
  has_profitable_order,
  total_profit,
  total_orders
FROM customer_profit_timeline
ORDER BY days_to_first_profit DESC NULLS LAST, total_profit DESC
```

Код кастомного теста test_is_positive.sql

```
-- tests/generic/test_is_positive.sql
{% test is_positive(model, column_name) %}
SELECT *
FROM {{ model }}
WHERE {{ column_name }} < 0
{% endtest %}
```

```
(dbt-env) dev@dev-vm:~/Downloads/pde_magistr/Data-Engineering-Platforms/modules/Module04/superstore_dwh_advanced$ dbt test --select test type:generic
20:49:57 Found 6 models, 1 snapshot, 49 data tests, 6 sources, 3 exposures, 435 macros
20:49:57
20:49:57 Concurrency: 4 threads (target='dev')
20:49:57
20:49:57 1 of 49 START test accepted values mart_valuable_dormant_customers_customer_status_DORMANT VALUABLE [RUN]
20:49:57 2 of 49 START test is_positive_mart_customer_ltv_average_order_value ..... [RUN]
20:49:57 3 of 49 START test is_positive_mart_customer_ltv_number_of_orders ..... [RUN]
20:49:57 4 of 49 START test is_positive_mart_customer_ltv_total_sales_lifetime ..... [RUN]
20:49:57 2 of 49 PASS is_positive_mart_customer_ltv_average_order_value ..... [PASS in 0.22s]
20:49:57 5 of 49 START test is_positive_mart_monthly_sales_number_of_orders ..... [RUN]
20:49:57 3 of 49 PASS is_positive_mart_customer_ltv_number_of_orders ..... [PASS in 0.23s]
20:49:57 6 of 49 START test is_positive_mart_monthly_sales_total_sales ..... [RUN]
20:49:57 1 of 49 PASS accepted values mart_valuable_dormant_customers_customer_status_DORMANT VALUABLE [PASS in 0.31s]
20:49:57 4 of 49 PASS is_positive_mart_customer_ltv_total_sales_lifetime ..... [PASS in 0.25s]
20:49:57 7 of 49 START test is_positive_mart_valuable_dormant_customers_avg_order_value . [RUN]
```

Рисунок 2 - Пример применения кастомного теста test_is_positive.sql

Код snapshot_product_dim.sql.

```
-- snapshots/snapshot_product_dim.sql
{% snapshot snapshot_product_dim %}
{{
    config(
        target_schema='dw_snapshots',
        strategy='check',
        unique_key='prod_id',
        check_cols=['segment', 'category'],
    )
}}
SELECT prod_id, product_id, segment, category FROM {{ source('dw_test', 'product_dim') }}
{% endsnapshot %}
```

Результаты

```
(dbt-env) dev@dev-vm:~/Downloads/pde_magistr/Data-Engineering-Platforms/modules/Module04/superstore_dwh_advanced$ dbt run
20:54:03 Running with dbt=1.10.11
20:54:03 Registered adapter: postgres=1.9.1
20:54:04 [WARNING]: Configuration paths exist in your dbt_project.yml file which do not apply to any resources.
There are 1 unused configuration paths:
- models.superstore_dwh_advanced.staging
20:54:04 Found 6 models, 1 snapshot, 49 data tests, 6 sources, 3 exposures, 435 macros
20:54:04 Concurrency: 4 threads (target='dev')
20:54:04 1 of 6 START sql view model public_dw_intermediate.int_sales_orders ..... [RUN]
20:54:05 1 of 6 OK created sql view model public_dw_intermediate.int_sales_orders ..... [CREATE VIEW in 0.23s]
20:54:05 2 of 6 START sql view model public_dw_intermediate.int_orders_pivoted ..... [RUN]
20:54:05 3 of 6 START sql table model public_dw_test.mart_customer_ltv ..... [RUN]
20:54:05 4 of 6 START sql table model public_dw_test.mart_monthly_sales ..... [RUN]
20:54:05 2 of 6 OK created sql view model public_dw_intermediate.int_orders_pivoted ..... [CREATE VIEW in 0.22s]
20:54:05 5 of 6 START sql table model public_dw_test.mart_time_to_first_profit ..... [RUN]
20:54:05 6 of 6 START sql table model public_dw_test.mart_valuable_dormant_customers .... [RUN]
20:54:05 3 of 6 OK created sql table model public_dw_test.mart_customer_ltv ..... [SELECT 1093 in 0.61s]
20:54:05 4 of 6 OK created sql table model public_dw_test.mart_monthly_sales ..... [SELECT 645 in 0.76s]
20:54:06 5 of 6 OK created sql table model public_dw_test.mart_time_to_first_profit ..... [SELECT 1093 in 0.70s]
20:54:06 6 of 6 OK created sql table model public_dw_test.mart_valuable_dormant_customers [SELECT 274 in 0.74s]
20:54:06 Finished running 4 table models, 2 view models in 0 hours 0 minutes and 1.58 seconds (1.58s).
20:54:06 Completed successfully
20:54:06 Done. PASS=6 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=6
```

Рисунок 3 - Скриншот успешного выполнения dbt run

```
(dbt-env) dev@dev-vm:~/Downloads/pde_magistr/Data-Engineering-Platforms/modules/Module04/superstore_dwh_advanced$ dbt test
20:55:02 38 of 49 START test not null mart_valuable_dormant_customers_first_order_date .. [RUN]
20:55:02 39 of 49 START test not null mart_valuable_dormant_customers_last_order_date ... [RUN]
20:55:02 36 of 49 PASS not null mart_valuable_dormant_customers_customer_status ..... [PASS in 0.20s]
20:55:02 40 of 49 START test not null mart_valuable_dormant_customers_sales_percentile .. [RUN]
20:55:03 37 of 49 PASS not null mart_valuable_dormant_customers_days_since_last_order ... [PASS in 0.24s]
20:55:03 41 of 49 START test not null mart_valuable_dormant_customers_segment ..... [RUN]
20:55:03 39 of 49 PASS not null mart_valuable_dormant_customers_last_order_date ..... [PASS in 0.20s]
20:55:03 38 of 49 PASS not null mart_valuable_dormant_customers_first_order_date ..... [PASS in 0.22s]
20:55:03 42 of 49 START test not null mart_valuable_dormant_customers_state ..... [RUN]
20:55:03 43 of 49 START test not null mart_valuable_dormant_customers_total_orders ..... [RUN]
20:55:03 40 of 49 PASS not null mart_valuable_dormant_customers_sales_percentile ..... [PASS in 0.21s]
20:55:03 44 of 49 START test not null mart_valuable_dormant_customers_total_profit ..... [RUN]
20:55:03 41 of 49 PASS not null mart_valuable_dormant_customers_segment ..... [PASS in 0.20s]
20:55:03 45 of 49 START test not null mart_valuable_dormant_customers_total_quantity .... [RUN]
20:55:03 43 of 49 PASS not null mart_valuable_dormant_customers_total_orders ..... [PASS in 0.18s]
20:55:03 42 of 49 PASS not null mart_valuable_dormant_customers_state ..... [PASS in 0.21s]
20:55:03 46 of 49 START test not null mart_valuable_dormant_customers_total_sales ..... [RUN]
20:55:03 47 of 49 START test unique mart_customer_ltv_customer_id ..... [RUN]
20:55:03 44 of 49 PASS not null mart_valuable_dormant_customers_total_profit ..... [PASS in 0.23s]
20:55:03 45 of 49 PASS not null mart_valuable_dormant_customers_total_quantity ..... [PASS in 0.19s]
20:55:03 48 of 49 START test unique mart_time_to_first_profit_customer_id ..... [RUN]
20:55:03 49 of 49 START test unique mart_valuable_dormant_customers_customer_id ..... [RUN]
20:55:03 47 of 49 PASS unique mart_customer_ltv_customer_id ..... [PASS in 0.25s]
20:55:03 46 of 49 PASS not null mart_valuable_dormant_customers_total_sales ..... [PASS in 0.29s]
20:55:03 49 of 49 PASS unique mart_valuable_dormant_customers_customer_id ..... [PASS in 0.17s]
20:55:03 48 of 49 PASS unique mart_time_to_first_profit_customer_id ..... [PASS in 0.19s]
20:55:03 Finished running 49 data tests in 0 hours 0 minutes and 3.81 seconds (3.81s).
20:55:04 Completed successfully
20:55:04 Done. PASS=49 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=49
```

Рисунок 4 - Скриншот успешного выполнения dbt test

```

• (dbt-env) dev@dev-vm:~/Downloads/pde_magistr/Data-Engineering-Platforms/modules/Module04/superstore_dwh_advanced$ dbt snapshot
20:55:41 Running with dbt=1.10.11
20:55:41 Registered adapter: postgres=1.9.1
20:55:42 [WARNING]: Configuration paths exist in your dbt_project.yml file which do not apply to any resources.
There are 1 unused configuration paths:
- models.superstore_dwh_advanced.staging
20:55:42 Found 6 models, 1 snapshot, 49 data tests, 6 sources, 3 exposures, 435 macros
20:55:42
20:55:42 Concurrency: 4 threads (target='dev')
20:55:42
20:55:43 1 of 1 START snapshot dw_snapshots.snapshot_product_dim ..... [RUN]
20:55:43 1 of 1 OK snapshot dw_snapshots.snapshot_product_dim ..... [SELECT 4644 in 0.49s]
20:55:43
20:55:43 Finished running 1 snapshot in 0 hours 0 minutes and 0.82 seconds (0.82s).
20:55:43
20:55:43 Completed successfully
20:55:43
20:55:43 Done. PASS=1 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=1

```

Рисунок 5 - Скриншот успешного выполнения dbt snapshot

```

(dbt-env) dev@dev-vm:~/Downloads/pde_magistr/Data-Engineering-Platforms/modules/Module04/superstore_dwh_advanced$ dbt show --select mart_time_to_first_profit -
-limit 50
20:57:11
Previewing node 'mart_time_to_first_profit':

```

customer_id	customer_name	first_order_date	first_profitable...	days_to_first_profit	has_profitable_order	...
TC-20980	Tamara Chand	2016-11-07	2016-11-07	0	True	...
RB-19360	Raymond Buch	2018-04-01	2018-04-01	0	True	...
SC-20095	Sanjit Chand	2016-02-12	2016-02-12	0	True	...
HL-15040	Hunter Lopez	2016-01-20	2016-01-20	0	True	...
AB-10105	Adrian Barton	2016-12-20	2016-12-20	0	True	...
TA-21385	Tom Ashbrook	2016-09-12	2016-09-12	0	True	...
CM-12385	Christopher Martinez	2017-03-16	2017-03-16	0	True	...
DR-12940	Daniel Raglin	2016-03-28	2016-03-28	0	True	...
BM-11650	Brian Moss	2016-07-09	2016-07-09	0	True	...
HW-14935	Helen Wasserman	2017-09-27	2017-09-27	0	True	...
JW-15220	Jane Waco	2017-04-30	2017-04-30	0	True	...
KD-16495	Keith Dawkins	2016-09-28	2016-09-28	0	True	...
AR-10540	Andy Reiter	2016-11-25	2016-11-25	0	True	...
SD-20485	Shirley Daniels	2016-01-26	2016-01-26	0	True	...
JK-15640	Jim Kriz	2016-09-19	2016-09-19	0	True	...
CC-12370	Christopher Conant	2018-05-23	2018-05-23	0	True	...
LA-16780	Laura Armstrong	2016-04-29	2016-04-29	0	True	...
RM-19675	Robert Marley	2016-11-14	2016-11-14	0	True	...
PS-19045	Penelope Sewall	2016-12-20	2016-12-20	0	True	...
HM-14860	Harry Marie	2016-07-21	2016-07-21	0	True	...
ME-17320	Maria Etezadi	2016-01-06	2016-01-06	0	True	...
JD-16150	Justin Deggeller	2016-11-16	2016-11-16	0	True	...
KM-16375	Katherine Murray	2016-07-20	2016-07-20	0	True	...
JG-15160	James Galang	2016-05-30	2016-05-30	0	True	...
DP-13390	Dennis Pardue	2016-07-05	2016-07-05	0	True	...
AB-10060	Adam Bellavance	2017-09-18	2017-09-18	0	True	...
TS-21370	Todd Sumrall	2016-10-28	2016-10-28	0	True	...
DR-12880	Dan Reichenbach	2017-09-25	2017-09-25	0	True	...

Рисунок 6 - Скриншот с данными из mart_time_to_first_profit.sql

Выводы

После выполнения этой лабораторной работы я понял, зачем нужны промежуточные модели и витрины вместо работы напрямую с таблицей фактов.

Основные плюсы которые я увидел:

1. Не нужно повторять один и тот же код

Вместо того чтобы в каждой витрине заново прописывать все JOIN'ы между таблицами, я сделал одну промежуточную модель `int_sales_orders`. Теперь все витрины используют её как основу. Это экономит время и уменьшает количество ошибок.

2. Проще разбираться

Когда я делал свою витрину `mart_time_to_first_profit`, мне не нужно было думать о том, как связаны все таблицы - я просто брал данные из готовой промежуточной модели. Это намного удобнее.

3. Легче тестировать

Я создал кастомный тест `is_positive` и применил его к нескольким витринам. Если бы я работал с одной большой таблицей фактов, тестировать было бы сложнее.

4. Быстрее работают запросы

Сложные вычисления делаются один раз в промежуточной модели, а витрины работают с уже подготовленными данными.

5. Удобно для бизнес-пользователей

Каждая витрина решает конкретную задачу. Например, моя витрина показывает время до первой прибыли по клиентам - это понятно и сразу виден результат.

Вывод: использовать промежуточные модели и витрины оказалось намного практичнее, чем работать с одной таблицей фактов. Код становится чище, работать быстрее, а разбираться в данных - проще.